

BÁO CÁO BÀI 1: KHẢO SÁT VÀ TIỀN XỬ LÝ DỮ LIỆU

Thực hiện: Nguyễn Trường Duy, Lý Gia Hào

Môn học: Khai thác dữ liệu

1. Bộ dữ liệu D1: Default of Credit Card (Nợ xấu Thẻ tín dụng)

1.1. Nguồn, giấy phép, quy mô

- Đường dẫn (Kaggle): [uciml/default-of-credit-card-clients-dataset](#)
- Đơn vị công bố: UCI Machine Learning Repository (Đại học Chung Hua & Đại học Tamkang, Đài Loan).
- Ngày tải: 09/2026.
- Quy mô ban đầu: 30.000 bản ghi và 25 thuộc tính. Dung lượng cực kỳ tối ưu (~2.8 MB).
- Quy mô sau tiền xử lý: Trích xuất 10.000 bản ghi đầu tiên để đồng bộ quy mô với các bộ dữ liệu khác trong đồ án.

Tên thuộc tính	Ý nghĩa thực tế	Kiểu dữ liệu	Thang đo	Miền giá trị
LIMIT_BAL	Hạn mức tín dụng được cấp (Gồm cả cá nhân và gia đình)	Số thực (Float)	Tỷ lệ	Giá trị ≥ 0

Tên thuộc tính	Ý nghĩa thực tế	Kiểu dữ liệu	Thang đo	Miền giá trị
EDUCATION	Trình độ học vấn của khách hàng	Số nguyên (Int)	Định danh	1 (Sau ĐH), 2 (ĐH), 3 (THPT)...
AGE	Tuổi của khách hàng	Số nguyên (Int)	Tỷ lệ	Giá trị ≥ 18
default.payment.next.month	Trạng thái nợ xấu (Tháng tiếp theo có trả nợ hay không)	Số nguyên (Int)	Định danh	0 (Trả đúng hạn) hoặc 1 (Nợ xấu)

1.3. Điều tra tri thức lĩnh vực & Lập luận kỹ thuật

- Bối cảnh nghiệp vụ: Dữ liệu phản ánh hồ sơ tín dụng và lịch sử thanh toán của khách hàng tại Đài Loan. Trong bối cảnh quản trị rủi ro ngân hàng, việc phân tích các chỉ số như hạn mức (LIMIT_BAL), lịch sử trả nợ (các cột PAY_) giúp ngân hàng đánh giá khả năng thanh toán của người vay.
- Lập luận kỹ thuật khả thi:

- Phân lớp (Classification) - Tối ưu nhất: Bộ dữ liệu có sẵn biến mục tiêu rời rạc default.payment.next.month mang giá trị cốt lõi trong ngành tài chính. Sử dụng thuật toán Cây quyết định (Decision Tree) để phân lớp sẽ giúp ngân hàng tự động phê duyệt hoặc từ chối hồ sơ cấp thẻ mới.
- Gom cụm (Clustering) - Khả thi cao: Với các thuộc tính liên tục về số tiền đã tiêu và số tiền đã trả, K-Means có thể nhóm khách hàng thành các phân khúc (ví dụ: nhóm chi tiêu cao - trả đúng hạn, nhóm chi tiêu thấp - hay nợ đọng) để đưa ra chiến lược marketing phù hợp.
- Luật kết hợp (Association Rules) - Không phù hợp: Các bản ghi đại diện cho hồ sơ tính của từng cá nhân độc lập, không tồn tại cấu trúc "giỏ hàng" để tìm ra các quy luật xuất hiện đồng thời.

2. Bộ dữ liệu D2: Hotel Booking Demand (Dữ liệu Đặt phòng Khách sạn)

2.1. Nguồn, giấy phép, quy mô

- Đường dẫn (Kaggle): [jessemostipak/hotel-booking-demand](https://www.kaggle.com/jessemostipak/hotel-booking-demand)
- Đơn vị công bố: Jesse Mostipak (dữ liệu trích xuất từ 2 khách sạn thực tế ở Bồ Đào Nha).
- Ngày tải: 09/2026.
- Quy mô ban đầu: 119.390 bản ghi và 32 thuộc tính.
- Quy mô sau tiền xử lý: Trích xuất 10.000 bản ghi và 30 thuộc tính (đã loại bỏ 2 cột không mang giá trị khai phá là company và reservation_status_date).
- **2.2. Từ điển dữ liệu (Một số thuộc tính cốt lõi)**

Tên thuộc tính	Ý nghĩa thực tế	Kiểu dữ liệu	Thang đo	Miền giá trị
hotel	Loại hình khách sạn lưu trú	Chuỗi (String)	Định danh	Resort Hotel, City Hotel

Tên thuộc tính	Ý nghĩa thực tế	Kiểu dữ liệu	Thang đo	Miền giá trị
lead_time	Số ngày từ lúc đặt đến ngày nhận phòng	Số nguyên (Int)	Tỷ lệ	Các số nguyên ≥ 0
adr	Giá phòng trung bình mỗi ngày	Số thực (Float)	Tỷ lệ	Các giá trị số thực liên tục
is_canceled	Trạng thái hủy đặt phòng	Số nguyên (Int)	Định danh	0 (Không hủy) hoặc 1 (Đã hủy)

2.3. Điều tra tri thức lĩnh vực & Lập luận kỹ thuật

- Bối cảnh nghiệp vụ: Bộ dữ liệu phản ánh nghiệp vụ quản trị lưu trú, ghi nhận đầy đủ hành vi đặt phòng (số người, loại bữa ăn, thời gian đặt, quốc tịch khách hàng). Mục tiêu kinh doanh ở đây là tối ưu hóa doanh thu và dự báo tỷ lệ lấp đầy phòng trống.
- Lập luận kỹ thuật khả thi:
 - Phân lớp (Classification) - Tối ưu nhất: Biến mục tiêu rời rạc is_canceled có giá trị kinh doanh cực lớn. Xây dựng mô hình phân lớp sẽ giúp khách sạn dự đoán trước khả năng một khách hàng có hủy phòng hay không.
 - Luật kết hợp (Association Rules) - Khả thi cao: Các bản ghi hoàn toàn có thể xem là một "giỏ" yêu cầu (gồm loại phòng, gói bữa ăn, bãi đỗ xe...). Áp dụng luật kết hợp sẽ tìm ra quy luật bán chéo (VD: Khách ở Resort thường mua kèm gói ăn 3 bữa).
 - Gom cụm (Clustering) - Khả thi: Dựa trên các đặc điểm nhân khẩu học và số ngày lưu trú, có thể phân khách hàng thành các phân khúc tương đồng (ví dụ: nhóm đi công tác ngắn ngày, nhóm gia đình nghỉ dưỡng).

3. Bộ dữ liệu D3: Groceries (Dữ liệu Giao dịch Siêu thị)

3.1. Nguồn, giấy phép, quy mô

- Đường dẫn (Kaggle): heeraldedhia/groceries-dataset
- Đơn vị công bố: Heeral Dedhia (tổng hợp từ dữ liệu bán lẻ).
- Ngày tải: 09/2026.
- Quy mô ban đầu: 38.765 bản ghi và 3 thuộc tính.
- Quy mô sau tiền xử lý: Chuyển đổi thành dạng "giỏ hàng" (transactions) tạo ra gần 15.000 giỏ hàng độc lập với hơn 160 thuộc tính (mặt hàng).

3.2. Từ điển dữ liệu (Dữ liệu gốc)

Tên thuộc tính	Ý nghĩa thực tế	Kiểu dữ liệu	Thang đo	Miền giá trị
Member_number	Mã định danh khách hàng	Số nguyên (Int)	Định danh	Các số nguyên dương
Date	Ngày thực hiện giao dịch	Chuỗi (Date/String)	Khoảng	Định dạng dd-mm-yyyy
itemDescription	Tên mặt hàng được mua	Chuỗi (String)	Định danh	Sữa, rau củ, thịt bò...

3.3. Điều tra tri thức lĩnh vực & Lập luận kỹ thuật

- Bối cảnh nghiệp vụ: Bộ dữ liệu ghi nhận lịch sử mua sắm thực tế tại một siêu thị. Mỗi dòng dữ liệu đại diện cho một mặt hàng được một khách hàng (Member_number) mua vào một ngày cụ thể (Date). Khi nhóm các mặt hàng được mua bởi cùng một người trong cùng một ngày, chúng ta sẽ tái tạo được các hóa đơn mua sắm (hay còn gọi là các "giỏ hàng").
- Lập luận kỹ thuật khả thi:
 - Luật kết hợp (Association Rules) - Tối ưu nhất: Đặc thù cốt lõi của dữ liệu này là các bản ghi tự nhiên tạo thành các "giỏ" mục cùng xuất hiện. Do đó, áp dụng thuật toán Apriori hoặc FP-Growth là vô cùng lý tưởng để khai phá các tập phổ biến và quy luật mua kèm (Ví dụ: Khách hàng mua sữa và ngũ cốc thì khả năng cao sẽ mua thêm trái cây).
 - Gom cụm (Clustering) - Khả thi: Có thể áp dụng K-Means trên tần suất mua hàng để phân khúc khách hàng (Ví dụ: nhóm khách mua sỉ, nhóm khách mua lẻ tẻ), tuy nhiên cần phải thực hiện Feature Engineering phức tạp hơn.
 - Phân lớp (Classification) - Không phù hợp: Dữ liệu không có sẵn biến mục tiêu rời rạc mang ý nghĩa phân loại (nhãn dự đoán) nên không thích hợp để chạy Phân lớp.