

BÁO CÁO THỰC NGHIỆM BÀI 2: BÀI TOÁN PHÂN LỚP (CLASSIFICATION)

1. Kỹ thuật Tiền xử lý dữ liệu (Data Preprocessing)

Quá trình chuẩn bị dữ liệu được thực hiện cẩn trọng nhằm tối ưu hóa hiệu năng của các thuật toán học có giám sát và ngăn chặn hiện tượng rò rỉ dữ liệu (Data Leakage) từ tập kiểm thử:

- **Bộ D1 (UCI Credit):** Biến mục tiêu được xác định là `default.payment.next.month` (Dự đoán rủi ro nợ xấu). Dữ liệu được chia thành tập Huấn luyện (Train) và tập Kiểm thử (Test) theo tỷ lệ 80:20. Kỹ thuật chuẩn hóa `StandardScaler` được áp dụng, lưu ý chỉ fit trên tập Train và transform trên tập Test để đảm bảo tính khách quan của mô hình.
- **Bộ D2 (Hotel Bookings):** Biến mục tiêu là `is_canceled` (Dự đoán khách hủy phòng). Do dữ liệu chứa cả biến liên tục và biến hạng mục, kỹ thuật `ColumnTransformer` được triển khai để chuẩn hóa Z-score cho nhóm biến số lượng và nhị phân hóa (`OneHotEncoder`) cho nhóm biến phân loại trước khi đưa vào mô hình.
- **Bộ D3 (Groceries):** Để chuyển đổi bài toán giỏ hàng sang bài toán phân lớp, mặt hàng phổ biến nhất là `whole milk` được trích xuất làm biến mục tiêu (Nhãn 1 = Có mua, 0 = Không mua). Kỹ thuật `TransactionEncoder` được sử dụng để biến đổi các giao dịch thô thành ma trận đặc trưng Boolean.

2. Thiết lập Mô hình và Khắc phục Mất cân bằng lớp

- **Trên bộ D1 và D2:** Thực nghiệm triển khai đối sánh hai thuật toán phân lớp cơ bản là **Decision Tree** (Cây quyết định, giới hạn `max_depth` để tránh Overfitting) và **k-NN** (K-Láng giềng gần nhất với số cụm `n_neighbors=5`).
- **Trên bộ D3:** Do biến mục tiêu bị mất cân bằng trầm trọng (số lượng người không mua `whole milk` áp đảo), mô hình **Decision Tree** được cấu hình tham số `class_weight='balanced'` nhằm phạt nặng các lỗi phân loại sai trên lớp thiểu số. Đồng thời, thuật toán **Naive Bayes** (cụ thể là `MultinomialNB`) được đưa vào thực nghiệm vì đây là thuật toán tối ưu cho không gian đặc trưng nhị phân và thưa thớt.

3. Phân tích kết quả thực nghiệm trên D1 (UCI Credit)

```

... === BÀI 2 - PHẦN 1: DỰ ĐOÁN NỢ XẤU (D1) ===

-> BÁO CÁO KẾT QUẢ: DECISION TREE
      precision    recall  f1-score   support

         0         0.84        0.95        0.89        4687
         1         0.65        0.37        0.47        1313

    accuracy          0.82        6000
   macro avg          0.75        6000
  weighted avg          0.80        6000

-> BÁO CÁO KẾT QUẢ: k-NN
      precision    recall  f1-score   support

         0         0.84        0.92        0.87        4687
         1         0.55        0.36        0.43        1313

    accuracy          0.80        6000
   macro avg          0.69        6000
  weighted avg          0.77        6000

```

Nhận xét D1:

- Chỉ số quan trọng nhất trong bài toán nợ xấu tài chính là **Recall của lớp 1** (Khả năng phát hiện đúng khách hàng sẽ bùng nợ). Nếu Recall quá thấp, ngân hàng sẽ chịu rủi ro mất vốn lớn.
- Dựa trên thực nghiệm, Decision Tree cho ra sự cân bằng tốt hơn. Thuật toán k-NN thường bị giảm hiệu năng trong không gian đa chiều và bị nhiễu bởi các biến không quan trọng, trong khi Decision Tree có khả năng tự động chọn lọc các nút đặc trưng mang tính quyết định (như PAY_AMT hay LIMIT_BAL).

4. Phân tích kết quả thực nghiệm trên D2 (Hotel Bookings)

```

... === BÀI 2 - PHẦN 1.5: DỰ ĐOÁN HỦY PHÒNG (D2) ===

-> BÁO CÁO KẾT QUẢ: DECISION TREE (D2)
      precision    recall  f1-score   support

         0         0.76        0.85        0.80        1231
         1         0.71        0.58        0.63         769

    accuracy          0.74        2000
   macro avg          0.73        2000
  weighted avg          0.74        2000

-> BÁO CÁO KẾT QUẢ: k-NN (D2)
      precision    recall  f1-score   support

         0         0.76        0.83        0.79        1231
         1         0.68        0.57        0.62         769

    accuracy          0.73        2000
   macro avg          0.72        2000
  weighted avg          0.73        2000

```

Nhận xét D2:

- Trong bài toán quản trị khách sạn, việc phát hiện sớm các khách hàng có ý định hủy phòng có ý nghĩa sống còn giúp tối ưu hóa công suất buồng phòng (tránh overbooking sai lầm).
- Thực nghiệm cho thấy **Decision Tree** vượt trội hơn hẳn k-NN trong việc xử lý không gian dữ liệu sau khi One-hot Encoding. Các nút cắt của Cây quyết định dễ dàng phân tách được những đặc trưng mang tính quyết định cao như thời gian đặt trước (lead_time) hay số lượng yêu cầu đặc biệt, giúp dự đoán chính xác hơn hành vi hủy phòng.

5. Phân tích kết quả thực nghiệm trên D3 (Groceries)

```
=== BÀI 2 - PHẦN 2: DỰ ĐOÁN MUA 'WHOLE MILK' (D3) ===
...
-> BÁO CÁO KẾT QUẢ: DECISION TREE (CÂN BẰNG LỚP)
      precision    recall  f1-score   support

         0         1.00      0.32      0.48      7264
         1         0.09      1.00      0.17       490

   accuracy          0.36      7754
  macro avg          0.55      0.66      0.32      7754
 weighted avg          0.94      0.36      0.46      7754

-> BÁO CÁO KẾT QUẢ: NAIVE BAYES
      precision    recall  f1-score   support

         0         0.94      1.00      0.97      7264
         1         1.00      0.01      0.02       490

   accuracy          0.94      7754
  macro avg          0.97      0.50      0.49      7754
 weighted avg          0.94      0.94      0.91      7754
```

Nhận xét D3:

- Phân lớp trên dữ liệu giỏ hàng siêu thị là một bài toán khó. Việc áp dụng cơ chế tự cân bằng lớp cho Decision Tree đã ép mô hình phải nhận diện lớp thiểu số tốt hơn (cải thiện Recall), dù phải đánh đổi bằng việc Precision giảm xuống (tăng tỷ lệ dương tính giả).
- Đúng với cơ sở lý thuyết, thuật toán **Naive Bayes** tỏ ra cực kỳ phù hợp với ma trận Boolean của giỏ hàng. Nhờ tính toán dựa trên xác suất độc lập có điều kiện, Naive Bayes xử lý không gian đặc trưng rời rạc tối ưu và nhẹ bèn hơn hẳn so với các nhát cắt cứng nhắc của thuật toán Cây quyết định.