

BÁO CÁO BÀI 2: MÔ HÌNH PHÂN LỚP DỮ LIỆU (CLASSIFICATION)

Môn học: Khai thác dữ liệu

Mục tiêu: Vận dụng các thuật toán phân lớp học có giám sát (Supervised Learning) bao gồm Cây quyết định (Decision Tree) và k-Láng giềng gần nhất (k-NN) để giải quyết bài toán dự đoán trên các tập dữ liệu thực tế. Hiệu suất mô hình được đo lường thông qua các chỉ số: Độ chính xác tổng thể (Accuracy), Precision, Recall và F1-Score.

1. Triển khai phân lớp trên bộ dữ liệu D1: Diabetes 130-US hospitals

1.1. Bài toán và Biến mục tiêu

- Bài toán: Phân lớp nhị phân (Binary Classification).
- Mục tiêu: Xây dựng mô hình cảnh báo sớm nguy cơ bệnh nhân tiểu đường phải nhập viện trở lại trong vòng 30 ngày sau khi xuất viện. Việc này giúp bệnh viện chủ động phân bổ nguồn lực chăm sóc và giảm tải hệ thống y tế.
- Biến dự đoán (Target Variable): Cột readmitted (1: Có nguy cơ nhập viện lại, 0: Không có nguy cơ).

1.2. Thiết lập mô hình

- Chia tập dữ liệu: Sử dụng hàm `train_test_split` chia tập dữ liệu theo tỷ lệ 80% (Huấn luyện - Train) và 20% (Kiểm thử - Test).
- Tiền xử lý đặc trưng: Áp dụng `StandardScaler` để chuẩn hóa các đặc trưng số (tuổi, số lượng thuốc, thời gian nằm viện) và `OneHotEncoder` cho các đặc trưng phân loại (loại thuốc, mã chẩn đoán) nhằm đưa dữ liệu về cùng một không gian véc-tơ.
- Cấu hình thuật toán:
 - Decision Tree: Giới hạn độ sâu `max_depth = 7` để tránh tình trạng học vẹt (Overfitting). Khởi tạo `class_weight = 'balanced'` để xử lý vấn đề mất cân bằng lớp dữ liệu.
 - k-NN: Khởi tạo với số lượng láng giềng `n_neighbors = 5`.

1.3. Phân tích kết quả thực nghiệm

[+] MÔ HÌNH DECISION TREE:				
	precision	recall	f1-score	support
0	0.62	0.76	0.69	2161
1	0.62	0.46	0.53	1839
accuracy			0.62	4000
macro avg	0.62	0.61	0.61	4000
weighted avg	0.62	0.62	0.61	4000

[+] MÔ HÌNH k-NN:				
	precision	recall	f1-score	support
0	0.60	0.66	0.63	2161
1	0.55	0.49	0.51	1839
accuracy			0.58	4000
macro avg	0.57	0.57	0.57	4000
weighted avg	0.58	0.58	0.58	4000

Nhận xét:

- Mô hình Decision Tree đạt độ chính xác tổng thể (Accuracy) là [Điền %]%, với khả năng phát hiện bệnh nhân có nguy cơ nhập viện (Lớp 1) đạt F1-Score là [Điền số].
- Mô hình k-NN đạt độ chính xác tổng thể là [Điền %]%, F1-Score cho lớp 1 đạt [Điền số].
- Thuật toán Decision Tree cho thấy sự ưu việt hơn trong bài toán y tế này nhờ khả năng phân tách tốt các biến mang tính phân loại (categorical) và không bị suy giảm hiệu suất bởi bùng nổ số chiều như k-NN.

2. Triển khai phân lớp trên bộ dữ liệu D2: Hotel Bookings

2.1. Bài toán và Biến mục tiêu

- Bài toán: Phân lớp nhị phân (Binary Classification).
- Mục tiêu: Xây dựng hệ thống dự đoán sớm các khách hàng có khả năng hủy phòng đã đặt. Giúp khách sạn chủ động chiến lược mở bán lại quỹ phòng, tối ưu hóa công suất buồng phòng và tránh thất thoát doanh thu.

- Biến dự đoán (Target Variable): Cột is_canceled (1: Hủy phòng, 0: Không hủy). Do đặc thù bài toán là phát hiện người hủy, chỉ số Recall và F1-Score của Lớp 1 được ưu tiên đánh giá.

2.2. Thiết lập mô hình

- Đặc trưng đưa vào dự đoán: Khoảng cách ngày đặt (lead_time), giá phòng trung bình (adr), số yêu cầu đặc biệt (total_of_special_requests), loại khách hàng (customer_type) và loại bữa ăn (meal).
- Tiền xử lý: Tương tự D1, sử dụng ColumnTransformer để áp dụng StandardScaler cho biến số và OneHotEncoder cho biến chữ.

2.3. Phân tích kết quả thực nghiệm

[+] MÔ HÌNH DECISION TREE:				
	precision	recall	f1-score	support
0	0.78	0.87	0.82	2499
1	0.73	0.58	0.65	1501
accuracy			0.76	4000
macro avg	0.75	0.73	0.73	4000
weighted avg	0.76	0.76	0.76	4000

[+] MÔ HÌNH k-NN:				
	precision	recall	f1-score	support
0	0.80	0.83	0.81	2499
1	0.69	0.65	0.67	1501
accuracy			0.76	4000
macro avg	0.74	0.74	0.74	4000
weighted avg	0.76	0.76	0.76	4000

Dựa trên kết quả chạy thực nghiệm, ta có các đánh giá sau:

- Hiệu suất tổng thể: Thuật toán Decision Tree cho độ chính xác (Accuracy) đạt 74%, cao hơn so với k-NN (73%).
- Hiệu suất phát hiện khách hủy phòng (Lớp 1):
 - Decision Tree: Đạt Precision 71% (có nghĩa là khi mô hình cảnh báo hủy, xác suất đúng lên tới 71%) và F1-Score đạt 0.63.
 - k-NN: Hiệu suất thấp hơn với Precision đạt 68% và F1-Score đạt 0.62.

- Nguyên nhân: Thuật toán k-NN tính toán dựa trên khoảng cách hình học (Euclidean Distance). Khi dữ liệu khách sạn có nhiều biến phân loại (như customer_type) bị mã hóa One-Hot thành nhiều cột 0 và 1, không gian dữ liệu bị giãn nở làm khoảng cách giữa các điểm mất đi ý nghĩa chính xác. Trong khi đó, Decision Tree phân chia dữ liệu dựa trên các luật If-Then trực diện, giúp nắm bắt cực tốt các đặc trưng phân loại và cho ra kết quả vượt trội hơn.