

BÁO CÁO THỰC NGHIỆM BÀI 3: KHAI PHÁ LUẬT KẾT HỢP (ASSOCIATION RULES)

1. Mục tiêu và Cơ sở lý thuyết

Thực nghiệm này ứng dụng thuật toán **Apriori** để rà soát không gian dữ liệu, nhằm phát hiện các mẫu hình vắng lai (Frequent Itemsets) và trích xuất các quy luật kết hợp. Sức mạnh của một quy luật $A \rightarrow B$ được đánh giá qua 3 hệ số lỗi:

- **Độ hỗ trợ (Support):** Đo lường tỷ lệ giao dịch chứa cả A và B trên tổng số giao dịch.

$$Support(A \rightarrow B) = \frac{freq(A \cup B)}{N}$$

- **Độ tin cậy (Confidence):** Xác suất xuất hiện của B khi biết A đã xuất hiện.

$$Confidence(A \rightarrow B) = \frac{freq(A \cup B)}{freq(A)}$$

- **Độ nâng (Lift):** Đo lường mức độ tương quan động. Nếu $Lift > 1$, A và B có sự phụ thuộc tích cực (thúc đẩy nhau xuất hiện).

$$Lift(A \rightarrow B) = \frac{Support(A \cup B)}{Support(A) \times Support(B)}$$

2. Tiền xử lý dữ liệu (Data Preprocessing)

Quá trình chuyển đổi dữ liệu được thiết kế riêng biệt để phù hợp với đặc thù phân phối của từng bộ:

- **Bộ D2 (Hotel Bookings):** Bản chất là dữ liệu dạng bảng (Tabular). Để áp dụng thuật toán khai phá giỏ hàng, tiến hành rời rạc hóa (Discretization) biến liên tục `lead_time` thành 3 nhóm (Short, Medium, Long) thông qua hàm `pd.qcut`. Các biến phân loại được binarize (nhị phân hóa) bằng One-hot Encoding, biến mỗi giá trị thành một "món hàng" ảo trong giỏ.
- **Bộ D3 (Groceries):** Bản chất là dữ liệu giao dịch tự nhiên. Sử dụng kỹ thuật `TransactionEncoder` để chuyển đổi danh sách các mặt hàng thô thành Ma trận thưa Boolean (Boolean Sparse Matrix), giúp thuật toán tối ưu hóa chi phí duyệt cây không gian.

3. Phân tích kết quả thực nghiệm trên D2 (Hotel Bookings)

- **Cấu hình tham số:** Không gian dữ liệu sau khi mã hóa One-hot khá dày đặc. Thuật toán hoạt động ổn định ở cấu hình $\text{min_support} = 0.1$ (10%) và $\text{min_confidence} = 0.5$ (50%).
- **Sàng lọc quy luật:** Sau khi áp dụng bộ lọc $\text{Lift} > 1.0$, hệ thống chắt lọc được 33 quy luật mang giá trị thực tiễn.
- **Nhận xét nghiệp vụ:** Dữ liệu phản ánh rõ hành vi của khách hàng. Phổ biến nhất là quy luật: Khách hàng đặt phòng ngắn ngày ($\text{lead_time_bin_Short}$) tại Resort Hotel có tỷ lệ rất cao (Confidence xấp xỉ 70%) sẽ chọn gói ăn sáng (meal_BB) và thuộc tệp khách vắng lại ($\text{customer_type_Transient}$). Tri thức này có thể dùng để tối ưu hóa các combo du lịch ngắn ngày.

TOP 3 LUẬT MẠNH NHẤT CỦA D2:

	antecedents \			
0	(hotel_Resort Hotel, lead_time_bin_Short)			
1	(lead_time_bin_Short)			
2	(lead_time_bin_Short)			

	consequents	support	confidence \
0	(customer_type_Transient, meal_BB)	0.2372	0.698469
1	(customer_type_Transient, meal_BB)	0.2372	0.698469
2	(customer_type_Transient, hotel_Resort Hotel, ...)	0.2372	0.698469

	lift
0	1.259864
1	1.259864
2	1.259864

4. Phân tích kết quả thực nghiệm trên D3 (Groceries)

- Xử lý sự cố dữ liệu phân tán (Sparsity Problem): Đặc thù của dữ liệu bán lẻ là ma trận cực kỳ thưa (độ phân tán cao). Thực nghiệm ban đầu cho thấy, nếu giữ nguyên ngưỡng Support lớn, hệ thống rơi vào trạng thái "Empty DataFrame" (không tìm thấy quy luật).
- Hiệu chỉnh siêu tham số: Để giải quyết bài toán "bùng nổ tổ hợp" nhưng vẫn không bỏ sót quy luật ngầm, thuật toán được ép hạ chuẩn Support xuống mức 0.01 (1%) và Confidence xuống 0.05 (5%), đồng thời sử dụng bộ lọc $\text{Lift} > 1.0$ để làm chốt chặn cuối cùng, loại bỏ các luật sinh ra do ngẫu nhiên.
- Nhận xét nghiệp vụ: Thuật toán đã bóc tách thành công các mối quan hệ chéo (Cross-selling) giữa các nhu yếu phẩm. Dù tỷ lệ Support tổng thể thấp (do lượng mặt hàng quá đa dạng), nhưng giá trị Lift lớn mạnh mẽ khẳng định khách hàng luôn có xu hướng mua nhóm thực phẩm này kèm theo nhóm thực phẩm khác trong cùng một chu kỳ đi siêu thị.

TOP 3 LUẬT MẠNH NHẤT CỦA D3:				
antecedents \				
0	(rolls/buns, yogurt)			
1	(other vegetables, whole milk, sausage)			
2	(rolls/buns, other vegetables, yogurt)			
consequents support confidence lift				
0	(other vegetables, whole milk, sausage)	0.013597	0.122120	2.428689
1	(rolls/buns, yogurt)	0.013597	0.270408	2.428689
2	(whole milk, sausage)	0.013597	0.259804	2.428575

5. Kết luận chung

Thực nghiệm Khai phá luật kết hợp đã chứng minh nguyên lý cơ bản trong Data Mining: Việc tinh chỉnh siêu tham số không thể cứng nhắc áp dụng chung một khuôn mẫu. Đối với ma trận dày đặc (D2), cần nâng cao ngưỡng Support để tránh rác dữ liệu. Ngược lại, với ma trận siêu phân tán (D3), bắt buộc phải hạ thấp ngưỡng Support kết hợp với bộ lọc Lift để khai thác triệt để các tri thức tiềm ẩn.