

BÁO CÁO BÀI 4: GOM CỤM DỮ LIỆU (CLUSTERING)

Môn học: Khai thác dữ liệu


Mục tiêu: Áp dụng thuật toán học không giám sát K-Means để tự động phân nhóm các điểm dữ liệu có đặc điểm tương đồng mà không cần sử dụng nhãn (labels) có sẵn. Phương pháp này giúp phát hiện ra các phân khúc ẩn trong tập khách hàng và các nhóm hành vi mạng bất thường.

4.1. Phân khúc khách hàng trên bộ dữ liệu D2 (Hotel Bookings)

4.1.1. Thiết lập bài toán

- Đặc trưng phân cụm: Thời gian đặt phòng trước (lead_time) và Giá phòng trung bình (adr).
- Tiền xử lý: Loại bỏ các giao dịch nhiễu (outliers) có giá phòng quá cao ($adr > 1000$) và chuẩn hóa dữ liệu bằng StandardScaler.
- Tham số mô hình: Khởi tạo số cụm $k = 3$ nhằm chia khách hàng thành 3 phân khúc tiêu biểu.

4.1.2. Phân tích kết quả thực nghiệm



Dựa trên biểu đồ phân tán (Scatter Plot) sau khi chạy K-Means, thuật toán đã chia tập khách hàng thành 3 cụm (Clusters) mang đặc điểm sinh thái kinh doanh rõ rệt:


- Cụm 0 (Nhóm cận ngày): Gồm những khách hàng có lead_time thấp (đặt phòng sát ngày đi) và adr ở mức trung bình - thấp. Đây thường là khách đi công tác đột xuất hoặc khách vắng lại.
- Cụm 1 (Nhóm lên kế hoạch sớm): Có lead_time rất cao (đặt trước nhiều tháng) nhưng adr thấp. Đây là nhóm khách du lịch cá nhân hoặc gia đình có xu hướng săn phòng giá rẻ từ sớm.
- Cụm 2 (Nhóm VIP/Cao điểm): Dù thời gian đặt phòng đa dạng, nhưng giá phòng adr cực kỳ cao. Đây là nhóm khách hàng lưu trú ở các hạng phòng sang trọng (Suite/VIP) hoặc đặt vào các dịp lễ tết.
- Đề xuất kinh doanh: Khách sạn có thể thiết lập hệ thống giá động (Dynamic Pricing). Tăng giá phòng sát ngày đối với Cụm 0 vì họ ít nhạy cảm về giá (cần phòng gấp), và tung các voucher đặt sớm (Early Bird) để thu hút thêm Cụm 1 nhằm đảm bảo công suất phòng cơ bản.

4.2. Nhận diện hành vi mạng bất thường trên bộ dữ liệu D3 (NSL-KDD)

4.2.1. Thiết lập bài toán

- Đặc trưng phân cụm: Lượng dữ liệu gửi đi (src_bytes) và Lượng dữ liệu nhận về (dst_bytes).
- Tiền xử lý: Do dung lượng các gói tin mạng có độ chênh lệch cực lớn (từ vài byte đến hàng triệu byte), dữ liệu được ép kiểu Logarit tự nhiên ($\ln(x + 1)$) trước khi đưa vào mô hình nhằm thu hẹp phương sai, giúp các cụm không bị kéo lệch.
- Tham số mô hình: Khởi tạo $k = 2$ để chia lưu lượng mạng thành 2 trạng thái: Bình thường và Bất thường.

4.2.2. Phân tích kết quả thực nghiệm



Kết quả gom cụm cho thấy bức tranh rõ nét về lưu lượng mạng truyền tải:

- Cụm 0 (Kết nối thông thường): Các điểm dữ liệu tập trung ở vùng có lượng byte gửi và nhận ổn định, tương ứng với các thao tác lướt web, gửi email hoặc truy vấn cơ sở dữ liệu bình thường.

- Cụm 1 (Kết nối bất thường - Dấu hiệu tấn công): Bao gồm các điểm dữ liệu phân tán mạnh, mang tính cục đoạn:
 - Hoặc lượng byte gửi đi cực lớn nhưng byte nhận về bằng 0 (Dấu hiệu của tấn công từ chối dịch vụ - DDoS/Flood).
 - Hoặc ngược lại, tải về lượng dữ liệu bất thường (Dấu hiệu của hành vi đánh cắp/rò rỉ dữ liệu - Data Exfiltration).
- Đánh giá thuật toán: Việc kết hợp Gom cụm K-Means (Bài 4) với Luật kết hợp Apriori (Bài 3) tạo ra một hệ thống phòng thủ đa lớp. Apriori bắt các cuộc tấn công đã biết dựa trên luật (Signature-based), trong khi K-Means tự động khoanh vùng các mối đe dọa mới lạ dựa trên sự bất thường của lưu lượng (Anomaly-based).