

BÁO CÁO THỰC NGHIỆM BÀI 4: PHÂN CỤM DỮ LIỆU (CLUSTERING) TRÊN D1 VÀ D2

1. Kỹ thuật Tiền xử lý Dữ liệu (Data Preprocessing)


Quá trình phân cụm sử dụng độ đo khoảng cách (Distance-based), do đó việc đồng nhất thang đo cho dữ liệu là bắt buộc:

- **Bộ D1 (UCI Credit):** Tập trung vào các đặc trưng số (LIMIT_BAL, AGE, BILL_AMT1, PAY_AMT1). Áp dụng kỹ thuật StandardScaler để đưa dữ liệu về phân phối chuẩn (mean = 0, variance = 1), triệt tiêu sự chênh lệch độ lớn giữa Hạn mức tín dụng và Độ tuổi.
- **Bộ D2 (Hotel Bookings):** Đối mặt với dữ liệu hỗn hợp (Mixed data). Kỹ thuật ColumnTransformer được triển khai để xử lý song song: StandardScaler cho các biến liên tục (lead_time, adr) và OneHotEncoder để nhị phân hóa các biến hạng mục (customer_type, meal). Cơ chế lấy mẫu ngẫu nhiên (Random Sampling 5,000 dòng) được áp dụng để tối ưu hóa chi phí tính toán phần cứng.

2. Xác định tham số cấu hình (Elbow Method)

Để đảm bảo tính khách quan trong việc chọn số lượng cụm (k), thực nghiệm tiến hành chạy thuật toán K-Means với $k \in [2, 8]$ và đánh giá mức độ hội tụ thông qua giá trị Inertia (Tổng bình phương khoảng cách nội cụm).

- Quan sát biểu đồ Elbow trên cả hai bộ dữ liệu D1 và D2, đường cong Inertia bắt đầu giảm tốc độ dốc rõ rệt và tạo thành điểm "khủy tay" tại vị trí $k = 3$.
- **Kết luận:** Tham số $k = 3$ được chốt làm cấu hình tiêu chuẩn cho mọi thuật toán phân cụm tiếp theo nhằm tránh hiện tượng Over-clustering (phân chia quá nát dữ liệu).



3. Đánh giá Hiệu năng: K-Means vs Agglomerative

Thực nghiệm đối sánh hai trường phái: **K-Means** (Dựa trên tâm cụm - Centroid) và **Agglomerative Clustering** (Phân cấp từ dưới lên - Hierarchical Bottom-up). Chất lượng được đo lường qua Silhouette Score (càng gần 1 càng tốt) và Davies-Bouldin Index (càng gần 0 càng tốt).

$$DB = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left(\frac{s_i + s_j}{d(c_i, c_j)} \right)$$

Phân tích kết quả thực nghiệm:

- **Trên bộ D1 (UCI Credit):** Thuật toán **Agglomerative** thể hiện sự áp đảo với chỉ số Silhouette đạt **0.4375** (so với 0.2909 của K-Means) và DBI tối ưu ở mức **0.8839** (so với 1.3246). Điều này minh chứng không gian tài chính mang tính phân cấp mạnh (khách nợ xấu là tập con của tập dư nợ), giúp phương pháp liên kết (Linkage) của Agglomerative bắt được hình thái cụm tốt hơn giả định hình cầu của K-Means.
- **Trên bộ D2 (Hotel Bookings):** Cán cân đảo chiều nghiêng về **K-Means** với Silhouette **0.2486** và DBI **1.4328** (so với 0.1802 và 1.6477 của Agglomerative). Dữ liệu sau khi One-hot Encoding bị đẩy lên không gian đa chiều thừa thớt, nơi cơ chế cập nhật trọng tâm (Centroid-updating) của K-Means hoạt động ổn định và kiểm soát nhiễu tốt hơn.

```
[1] Đang xử lý bộ dữ liệu D1 (UCI Credit)...
-> Đánh giá mô hình trên D1:
K-Means      - Silhouette: 0.2909 | Davies-Bouldin: 1.3246
Agglomerative - Silhouette: 0.4375 | Davies-Bouldin: 0.8839

=====

[2] Đang xử lý bộ dữ liệu D2 (Hotel Bookings)...
-> Đánh giá mô hình trên D2:
K-Means      - Silhouette: 0.2486 | Davies-Bouldin: 1.4328
Agglomerative - Silhouette: 0.1802 | Davies-Bouldin: 1.6477
```

4. Khắc họa chân dung cụm (Cluster Profiling)

Dựa trên việc phân tích tọa độ trọng tâm, hệ thống bóc tách được các nhóm hành vi cốt lõi:

Hồ sơ Khách hàng Tín dụng (D1):

- **Cụm 0 (Tiêu chuẩn):** Hạn mức vừa phải, chi tiêu và thanh toán ở mức độ cân bằng, rủi ro thấp.
- **Cụm 1 (Nhóm VIP):** LIMIT_BAL và BILL_AMT cực kỳ cao, đại diện cho tệp khách hàng mang lại biên lợi nhuận lớn nhất cho ngân hàng.

- Cụm 2 (Nhóm Rủi ro): Tỷ lệ PAY_AMT rất thấp so với dư nợ, độ tuổi trẻ, cần áp dụng các biện pháp thắt chặt tín dụng.

Hồ sơ Khách lưu trú (D2):

- Cụm 0 (Khách vắng lai): lead_time rất ngắn (đặt phòng sát ngày), ít yêu cầu đi kèm, thuộc nhóm Transient.
- Cụm 1 (Khách kế hoạch/Gia đình): lead_time dài (đặt trước nhiều tháng), thường mua kèm các gói bữa ăn (Meal).
- Cụm 2 (Khách cao cấp): Giá trị phòng trung bình (adr) cao nhất, phát sinh số lượng yêu cầu đặc biệt (total_of_special_requests) vượt trội.